Lagrange y KKT

Investigación Operativa

Universidad de San Andrés

Introducción: ¿de qué va esta clase?

En la clase anterior: resolvimos problemas no lineales con Python (caja negra).

Hoy abrimos la caja: ¿cómo se resuelven *analíticamente*?

Dos métodos:

- **Multiplicadores de Lagrange:** restricciones de **igualdad** ($g = 0$)
- **Condiciones KKT:** generaliza a **desigualdades** ($g \leq 0$)

Introducción: ¿por qué nos importa?

Si la compu lo resuelve sola con `scipy.optimize.minimize`, ¿para qué aprender esto?

1. **Entender por qué funcionan** los métodos numéricos que usamos
2. Obtener **precios sombra** (λ): interpretación económica muy potente
3. En algunos casos, la solución analítica es **más rápida y exacta** que la numérica

Para tener en cuenta

Lo que hacemos "a mano" hoy es exactamente lo que hace el solver por dentro. Los *KKT conditions* son el corazón de `scipy.optimize`.

Repaso: derivada parcial

La **derivada parcial de** $f(x, y)$ **respecto a** x $(\partial f/\partial x)$ se calcula tratando a todas las demás variables como **constantes**.

Ejemplo: si $f(x, y) = 3x^2y + 5y^3$:

- $\dfrac{\partial f}{\partial x} = 6xy$ (la y es constante, la $5y^3$ desaparece)
- $\dfrac{\partial f}{\partial y} = 3x^2 + 15y^2$ (la x es constante)

Truco mental
Tapá con la mano todas las variables excepto una y derivás como siempre.

Repaso: gradiente

El **gradiente** de f es el vector de todas las derivadas parciales:

$$\nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$

Interpretación geométrica: apunta en la dirección donde f **crece más rápido**. Su longitud dice qué tan rápido.

Ejemplo: $f(x, y) = x^2 + y^2$ (un cuenco parabólico).

$$\nabla f = (2x, 2y)$$

En $(3, 4)$: $\nabla f = (6, 8)$. Apunta hacia afuera del origen (donde f crece).

Repaso: reglas que vamos a usar mucho

1. Potencias: $\dfrac{d}{dx}x^n = n \cdot x^{n-1}$.

Incluye fracciones: $\dfrac{d}{dx}x^{0{,}5} = 0{,}5 \cdot x^{-0{,}5} = \dfrac{1}{2\sqrt{x}}$

2. Producto de dos variables: si $f = xy$, entonces:

- $\partial f / \partial x = y$
- $\partial f / \partial y = x$

Las variables "se cruzan".

3. Constante por función: la constante sale afuera.

$$\frac{d}{dx}(5x^2) = 5 \cdot 2x = 10x$$

¿Para qué sirve esto?

En los próximos métodos vamos a:

1. Construir una función llamada **Lagrangiano** $\mathcal{L}(x, y, \lambda)$
2. Calcular sus derivadas parciales respecto a x, y, λ
3. Igualar todas a cero: $\nabla \mathcal{L} = 0$
4. Resolver el sistema de ecuaciones resultante

En una frase
Todo se reduce a: construir la función correcta, derivar, igualar a cero, resolver.

Lagrange: la intuición geométrica

Queremos **minimizar** $f(x, y)$ sujeto a que (x, y) esté sobre la curva $g(x, y) = 0$.

Sin restricción, el mínimo podría estar en cualquier lado. Con la restricción, nos tenemos que quedar *solo* sobre esa curva.

Pregunta: caminando sobre la curva de restricción, ¿dónde está el punto más bajo de f?

Lagrange: la observación clave

En el punto óptimo, la **curva de nivel de** f (los puntos donde f vale lo mismo) es **tangente** a la curva de la restricción.

¿Por qué? Si se cruzaran, podríamos movernos un poquito sobre la restricción y mejorar f. Entonces el óptimo es donde se tocan sin cruzarse.

Y si dos curvas son tangentes en un punto, sus **gradientes son paralelos**:

$$\nabla f(x^*, y^*) = \lambda \cdot \nabla g(x^*, y^*)$$

Ese número λ (lambda) es el **multiplicador de Lagrange**.

Visualización: gradientes paralelos

$f = x^2 + y^2$ (círculos de nivel) sujeto a $x + y = 4$ (recta).

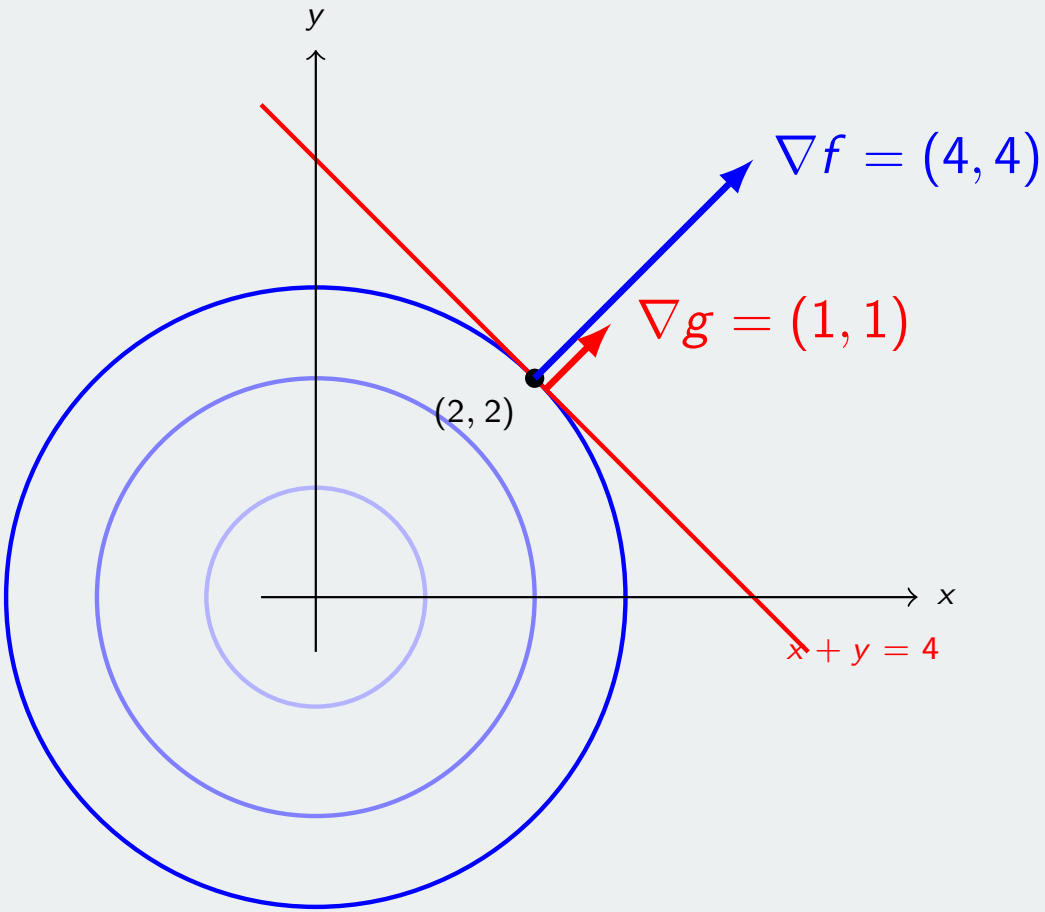

$\nabla f = 4 \cdot \nabla g$. Ese factor 4 es exactamente λ.

¿Por qué siempre son paralelos en el óptimo?

Razonamiento por contradicción.

Suponé que en el óptimo los gradientes **no** son paralelos. Entonces existe una dirección a lo largo de la restricción que tiene componente en la dirección de ∇f.

Moviéndote en esa dirección:

- Seguís sobre la restricción ($g = 0$)
- Cambiás f (porque hay componente en ∇f)

Si f cambia, podés mejorarla $\Rightarrow$ no estabas en el óptimo. **Contradicción.**

Conclusión
La única forma de estar en el óptimo es que $\nabla f \parallel \nabla g$: ninguna dirección sobre la curva cambia f.

El Lagrangiano

En vez de trabajar con $\nabla f = \lambda \nabla g$ separado, definimos una función nueva:

$$\mathcal{L}(x, y, \lambda) = f(x, y) - \lambda \cdot g(x, y)$$

Pedirle que $\nabla \mathcal{L} = 0$ **equivale a** pedir las tres cosas juntas:

- $\partial \mathcal{L}/\partial x = 0 \Rightarrow \partial f/\partial x = \lambda\, \partial g/\partial x$
- $\partial \mathcal{L}/\partial y = 0 \Rightarrow \partial f/\partial y = \lambda\, \partial g/\partial y$
- $\partial \mathcal{L}/\partial \lambda = 0 \Rightarrow g(x, y) = 0$ (¡la restricción!)

La gracia
Los gradientes paralelos **y** la restricción cumplida, todo en un solo paso de derivar.

¿Por qué el signo menos en $\mathcal{L} = f - \lambda g$?

Si derivamos $\mathcal{L} = f - \lambda g$ respecto a λ:

$$\frac{\partial \mathcal{L}}{\partial \lambda} = -g(x, y)$$

Igualando a cero: $-g(x, y) = 0 \Rightarrow g(x, y) = 0$. ✓

Y al derivar respecto a x:

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{\partial f}{\partial x} - \lambda \frac{\partial g}{\partial x} = 0 \Rightarrow \nabla f = \lambda \nabla g$$

El signo es **convención**. Algunos libros usan $\mathcal{L} = f + \lambda g$ (cambia el signo de λ pero es lo mismo).

El precio sombra (λ)

λ no es un número auxiliar cualquiera: tiene interpretación económica.

Definición

Precio sombra = cuánto cambiaría el valor óptimo de f si relajamos la restricción en **una unidad**.

Ejemplo: maximizamos ganancias con presupuesto de \$1000 y obtenemos $\lambda = 5$.

- Si el presupuesto fuera \$1001, las ganancias aumentarían $\approx$ \$5
- Si conseguir un dólar cuesta \$2 $\Rightarrow$ **conviene** pedirlo
- Si conseguir un dólar cuesta \$10 $\Rightarrow$ **no conviene**

Algoritmo de Lagrange paso a paso

1. **Identificar** la función objetivo f y la restricción $g(x, y) = 0$
2. **Construir** el Lagrangiano: $\mathcal{L} = f - \lambda \cdot g$
3. **Derivar** respecto a x, y, λ e igualar a cero
4. **Resolver** el sistema de ecuaciones
5. **Interpretar** λ como precio sombra

Aclaración importante

Lagrange nos da **candidatos** a óptimo (puntos críticos). Si tenemos varios, hay que evaluar f en cada uno. Si el problema es convexo, el candidato es directamente el óptimo global.

Ejemplo 1: enunciado

Problema
Encontrar el punto (x, y) que **minimice** $x^2 + y^2$ sujeto a que $x + y = 4$.

Interpretación geométrica:

- $x^2 + y^2$ es el cuadrado de la distancia al origen
- Minimizar eso sobre la recta $x + y = 4$ = punto de la recta más cercano al $(0, 0)$
- Es el círculo más chico centrado en el origen que llega a tocar la recta

Se podría resolver por geometría (perpendicular a la recta desde el origen), pero lo hacemos con Lagrange para ver cómo funciona.

Ejemplo 1: visualización

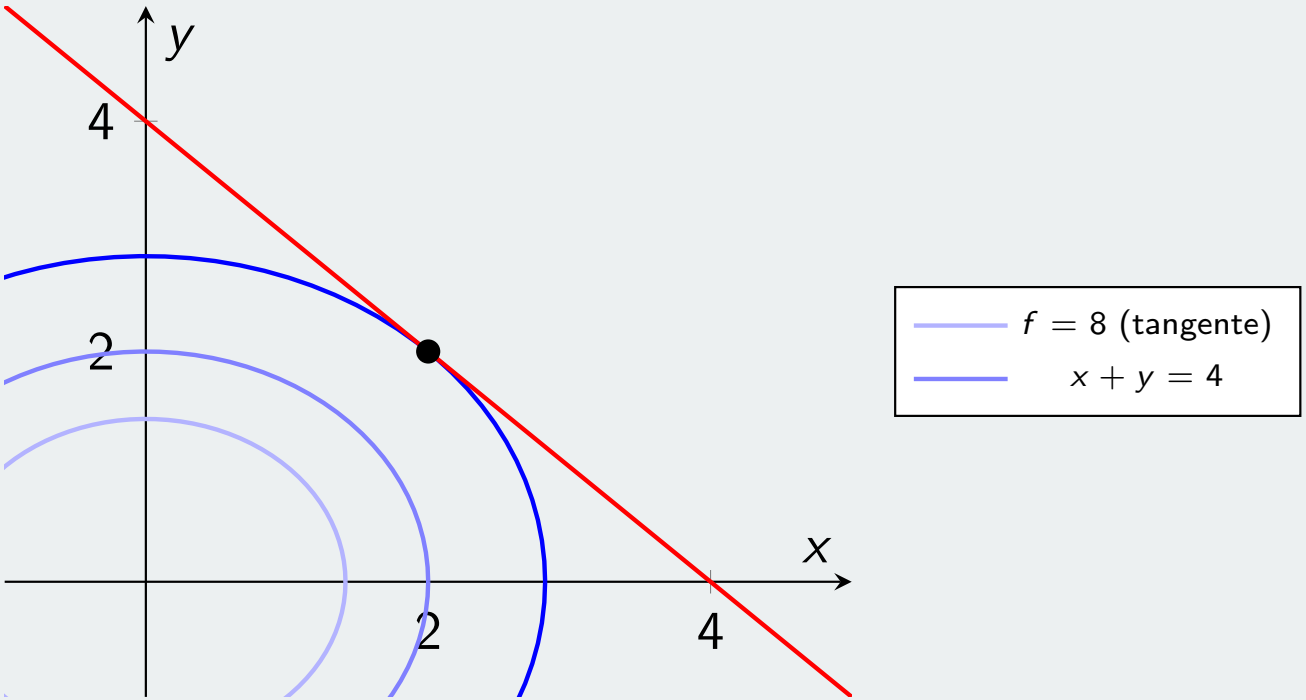

El círculo azul tangente a la recta roja tiene radio $\sqrt{8}$. El punto de tangencia es $(2, 2)$.

Ejemplo 1: paso 1 - Lagrangiano

Identificamos:

- Función objetivo: $f(x, y) = x^2 + y^2$
- Restricción: $g(x, y) = x + y - 4 = 0$

Construimos el Lagrangiano:

$$\mathcal{L}(x, y, \lambda) = (x^2 + y^2) - \lambda \cdot (x + y - 4)$$

Ejemplo 1: paso 2 - derivadas

Derivamos respecto a cada variable y igualamos a cero:

$$(1) \quad \frac{\partial \mathcal{L}}{\partial x} = 2x - \lambda = 0 \implies \lambda = 2x$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial y} = 2y - \lambda = 0 \implies \lambda = 2y$$

$$(3) \quad \frac{\partial \mathcal{L}}{\partial \lambda} = -(x + y - 4) = 0 \implies x + y = 4$$

Ojo

La ecuación (3) es siempre la restricción original. No te olvides de derivar respecto a λ, no es trampa.

Ejemplo 1: paso 3 - resolver el sistema

De (1) y (2): como $\lambda = 2x$ y $\lambda = 2y$:

$$2x = 2y \implies x = y$$

Reemplazamos en (3):

$$x + x = 4 \implies 2x = 4 \implies x = 2$$

Como $x = y$: $y = 2$.

Paso 4: calcular λ. Usando (1):

$$\lambda = 2x = 2 \cdot 2 = 4$$

$$\boxed{x^* = 2, \quad y^* = 2, \quad \lambda^* = 4}$$

Ejemplo 1: interpretación

Geométrica:

- En $(2, 2)$: $\nabla f = (2x, 2y) = (4, 4)$ y $\nabla g = (1, 1)$
- Efectivamente $\nabla f = 4 \cdot \nabla g$, por eso $\lambda = 4$

Precio sombra: si la restricción fuera $x + y = 5$ (aumentamos 1 unidad):

- Predicción: f aumenta ≈ 4
- Real: nuevo óptimo $(2{,}5, 2{,}5)$ con $f = 12{,}5$ (antes era 8)
- Aumento real: $12{,}5 - 8 = 4{,}5$. Muy cerca de la predicción de 4

Por qué no es exacto

El precio sombra es la **derivada** del valor óptimo respecto al parámetro. Vale exactamente para cambios infinitesimales, y es una buena aproximación para cambios chicos.

Ejemplo 1: resolución en Python

```python
from scipy.optimize import minimize

def objetivo(x):
    return x[0]**2 + x[1]**2

restricciones = [
    {'type': 'eq', 'fun': lambda x: x[0] + x[1] - 4}
]

res = minimize(objetivo, [0, 0], method='SLSQP',
               constraints=restricciones)

if res.success:
    print(f'x* = {res.x[0]:.4f}, y* = {res.x[1]:.4f}')
    print(f'f* = {res.fun:.4f}')
```

Ejemplo 2: enunciado

El Director de Producto de una empresa tecnológica lanza un nuevo **reloj inteligente**. El éxito depende de dos características:

- x: nivel de innovación en la **duración de la batería**
- y: nivel de innovación en la **calidad de la pantalla**

El consumidor no valora estas características por separado: las valora **de forma multiplicativa**. El valor percibido se modela como:

$$f(x, y) = xy$$

El costo crece **cuadráticamente** (materiales experimentales).
Presupuesto normalizado en 1:

$$x^2 + y^2 = 1$$

Ejemplo 2: ¿por qué multiplicativo?

Intuición

Si la pantalla es perfecta pero la batería dura una hora: el producto fracasa. Si la batería dura un mes pero la pantalla no se ve: también fracasa.

Con $f = xy$:

- $x = 10, y = 0 \Rightarrow f = 0$ (pantalla excelente pero sin batería: fracaso)
- $x = 0, y = 10 \Rightarrow f = 0$ (batería infinita pero no se ve: fracaso)
- $x = 5, y = 5 \Rightarrow f = 25$ (las dos decentes: éxito)

La función multiplicativa **castiga los extremos** y premia el balance.

Ejemplo 2: paso 1 - Lagrangiano

Identificamos:

- Objetivo: maximizar $f(x, y) = xy$
- Restricción: $g(x, y) = x^2 + y^2 - 1 = 0$

Lagrangiano:

$$\mathcal{L}(x, y, \lambda) = xy - \lambda(x^2 + y^2 - 1)$$

Ejemplo 2: paso 2 - derivadas

$$(1) \quad \frac{\partial \mathcal{L}}{\partial x} = y - 2\lambda x = 0 \implies \lambda = \frac{y}{2x}$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial y} = x - 2\lambda y = 0 \implies \lambda = \frac{x}{2y}$$

$$(3) \quad \frac{\partial \mathcal{L}}{\partial \lambda} = -(x^2 + y^2 - 1) = 0 \implies x^2 + y^2 = 1$$

Ejemplo 2: paso 3 - resolver

Igualando las dos expresiones de λ:

$$\frac{y}{2x} = \frac{x}{2y}$$

Multiplicando cruzado:

$$2y \cdot y = 2x \cdot x \implies 2y^2 = 2x^2 \implies y^2 = x^2$$

Reemplazando en (3):

$$x^2 + x^2 = 1 \implies 2x^2 = 1 \implies x^2 = \frac{1}{2} \implies x = \pm\frac{\sqrt{2}}{2}$$

Y como $y^2 = x^2$: $y = \pm\frac{\sqrt{2}}{2}$

Ejemplo 2: paso 4 - los 4 candidatos

Combinando los signos de x e y obtenemos **4 puntos críticos**:

Máximos globales ($f = 0{,}5$)
Cuando x e y tienen **el mismo signo**:

- $\left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}\right)$: $f = \frac{\sqrt{2}}{2} \cdot \frac{\sqrt{2}}{2} = \frac{2}{4} = 0{,}5$
- $\left(-\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2}\right)$: $f = (-)(-) = 0{,}5$

Mínimos globales ($f = -0{,}5$): signos opuestos

- $\left(\frac{\sqrt{2}}{2}, -\frac{\sqrt{2}}{2}\right)$ y $\left(-\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2}\right)$

Ejemplo 2: calcular λ

Para los máximos, usando la expresión $\lambda = y/(2x)$:

$$\lambda = \frac{\sqrt{2}/2}{2 \cdot \sqrt{2}/2} = \frac{\sqrt{2}/2}{\sqrt{2}} = \frac{1}{2}$$

$$\boxed{x^* = y^* = \tfrac{\sqrt{2}}{2} \approx 0{,}707, \quad \lambda^* = 0{,}5, \quad f^* = 0{,}5}$$

Interpretación:

- $\lambda = 0{,}5$: si expandimos el círculo (presupuesto $\to 1{,}1$), la sinergia crece a tasa 0,5
- Geométricamente: ∇f es la mitad de ∇g en el punto óptimo

Ejemplo 2: resolución en Python

```python
from scipy.optimize import minimize

# Minimizamos el negativo para maximizar
def objetivo_neg(x):
    return -x[0] * x[1]

restricciones = [
    {'type': 'eq', 'fun': lambda x: x[0]**2 + x[1]**2 - 1}
]

x0 = [0.5, 0.5]  # arrancamos en el cuadrante positivo

res = minimize(objetivo_neg, x0, method='SLSQP',
               constraints=restricciones)

if res.success:
    print(f'x* = {res.x[0]:.4f}, y* = {res.x[1]:.4f}')
    print(f'Sinergia maxima: {-res.fun:.4f}')
```

Ejemplo 3: enunciado

Una fábrica quiere maximizar la producción de juguetes. La producción se modela como una función **Cobb-Douglas** (típica en economía):

$$P(L, K) = 10 \cdot L^{0,5} \cdot K^{0,5}$$

- L: cantidad de horas de trabajo (mano de obra)
- K: cantidad de horas de máquina (capital)

Presupuesto diario: \$1000. **Costos:**

- \$20 por hora laboral
- \$50 por hora de máquina

Restricción de presupuesto: $20L + 50K = 1000$

Ejemplo 3: paso 1 - Lagrangiano

$$\mathcal{L}(L, K, \lambda) = 10L^{0,5}K^{0,5} - \lambda(20L + 50K - 1000)$$

Recordatorio: la derivada de $L^{0,5}$ es $0{,}5 \cdot L^{-0,5}$. Y $L^{-0,5} = 1/\sqrt{L}$.

Ejemplo 3: paso 2 - derivadas

$$(1) \quad \frac{\partial \mathcal{L}}{\partial L} = 10 \cdot 0{,}5 \cdot L^{-0{,}5} K^{0{,}5} - 20\lambda = 5L^{-0{,}5} K^{0{,}5} - 20\lambda = 0$$

Despejando λ:

$$\lambda = \frac{5K^{0{,}5}}{20L^{0{,}5}} = \frac{K^{0{,}5}}{4L^{0{,}5}}$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial K} = 5L^{0{,}5} K^{-0{,}5} - 50\lambda = 0 \implies \lambda = \frac{L^{0{,}5}}{10K^{0{,}5}}$$

$$(3) \quad 20L + 50K = 1000$$

Ejemplo 3: paso 3 - resolver

Igualamos las dos expresiones de λ:

$$\frac{K^{0,5}}{4L^{0,5}} = \frac{L^{0,5}}{10K^{0,5}}$$

Multiplicando cruzado:

$$10 \cdot K^{0,5} \cdot K^{0,5} = 4 \cdot L^{0,5} \cdot L^{0,5} \implies 10K = 4L \implies L = 2{,}5K$$

Reemplazamos en la restricción (3):

$$20 \cdot (2{,}5K) + 50K = 1000$$
$$50K + 50K = 1000 \implies 100K = 1000 \implies K = 10$$

Y entonces $L = 2{,}5 \cdot 10 = 25$.

Ejemplo 3: paso 4 - λ y producción

Calculamos λ:

$$\lambda = \frac{K^{0,5}}{4L^{0,5}} = \frac{\sqrt{10}}{4\sqrt{25}} = \frac{\sqrt{10}}{4 \cdot 5} = \frac{\sqrt{10}}{20} \approx 0{,}158$$

Producción óptima:

$$P(25, 10) = 10 \cdot \sqrt{25} \cdot \sqrt{10} = 10 \cdot 5 \cdot \sqrt{10} = 50\sqrt{10} \approx 158{,}11$$

$$\boxed{L^* = 25,\ K^* = 10,\ \lambda^* \approx 0{,}158,\ P^* \approx 158}$$

Ejemplo 3: interpretación

Regla de oro
$L = 2{,}5K$ es la **regla de mezcla óptima**. No depende del presupuesto.

¿Qué quiere decir esto? Si mañana nos aumentan el presupuesto a \$2000, la relación óptima **sigue siendo** $L = 2{,}5K$. Resolvemos:

$$20(2{,}5K) + 50K = 2000 \implies K = 20,\ L = 50$$

Precio sombra: $\lambda \approx 0{,}158$ juguetes por dólar.

- Presupuesto de \$1001 $\Rightarrow$ producción $\approx 158{,}27$ juguetes
- Si conseguir un dólar extra cuesta menos que 0.158 juguetes de valor $\Rightarrow$ conviene

Ejemplo 3: leyendo $1/\lambda$

El número $\lambda = 0{,}158$ juguetes por dólar es chico y difícil de leer. Mirando el **inverso**:

$$\frac{1}{\lambda} = \frac{1}{0{,}158} \approx 6{,}33 \quad \text{dólares por juguete}$$

Producir un juguete adicional nos **cuesta \$6.33 en el margen**. Ese es el *costo marginal* en el punto óptimo.

Uso práctico:

- Si el juguete se vende a \$10 $\Rightarrow$ margen de \$3.67 por unidad
- Si se vende a \$5 $\Rightarrow$ producir más **pierde plata**

Truco general
Cuando λ sale chico y con unidades raras, mirar $1/\lambda$ suele dar una interpretación más intuitiva.

Ejemplo 4: enunciado

Una empresa tecnológica desarrolla **Hardware** (x) y **Software** (y). Los productos no son independientes: compiten por recursos pero también se potencian. Función de beneficios (en miles de dólares):

$$B(x, y) = 50x - 0{,}5x^2 + 40y - y^2 + xy$$

Presupuesto: \$80k. Costos: \$1k por unidad de hardware, \$2k por unidad de software.

$$x + 2y = 80$$

Ejemplo 4: interpretación de cada término

$$B(x,y) = \underbrace{50x}_{\text{lineal}} - \underbrace{0{,}5x^2}_{\text{saturación}} + \underbrace{40y}_{\text{lineal}} - \underbrace{y^2}_{\text{saturación}} + \underbrace{xy}_{\text{sinergia}}$$

- $50x$**,** $40y$**:** beneficio base por cada unidad invertida
- $-0{,}5x^2$**,** $-y^2$**:** rendimientos decrecientes (el mercado se satura)
- $+xy$**: sinergia**. Un buen software hace al hardware más valioso, y viceversa

Observación del mercado real

El término cruzado $+xy$ es lo que distingue este ejemplo: no solo penaliza extremos (como en el reloj) sino que también **premia invertir en los dos juntos**.

Ejemplo 4: paso 1 - Lagrangiano

$$\mathcal{L}(x, y, \lambda) = (50x - 0{,}5x^2 + 40y - y^2 + xy) - \lambda(x + 2y - 80)$$

Ejemplo 4: paso 2 - derivadas

$$(1) \quad \frac{\partial \mathcal{L}}{\partial x} = 50 - x + y - \lambda = 0 \implies \lambda = 50 - x + y$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial y} = 40 - 2y + x - 2\lambda = 0 \implies 2\lambda = 40 + x - 2y$$

$$(3) \quad \frac{\partial \mathcal{L}}{\partial \lambda} = -(x + 2y - 80) = 0 \implies x + 2y = 80$$

Atención al término $+xy$

Al derivar xy respecto a x queda y. Al derivar respecto a y queda x. Por eso aparecen los cruzados $+y$ y $+x$ en las ecuaciones.

Ejemplo 4: paso 3 - igualar ecuaciones

Tenemos dos expresiones de λ. Para igualarlas, **multiplicamos (1) por 2**:

$$2(50 - x + y) = 40 + x - 2y$$

$$100 - 2x + 2y = 40 + x - 2y$$

Reordenamos (variables a un lado, números al otro):

$$100 - 40 = x + 2x - 2y - 2y \implies 60 = 3x - 4y$$

Entonces tenemos una nueva ecuación: $3x - 4y = 60$.

Ejemplo 4: paso 3 (sigue) - sistema lineal

Juntamos esta ecuación con la restricción:

$$\begin{cases} 3x - 4y = 60 \\ x + 2y = 80 \end{cases}$$

Multiplicamos la segunda por 2 para que las y se cancelen al sumar:

$$\begin{cases} 3x - 4y = 60 \\ 2x + 4y = 160 \end{cases}$$

Sumando verticalmente:

$$5x = 220 \implies x = 44$$

Reemplazando en la restricción: $44 + 2y = 80 \implies y = 18$.

Ejemplo 4: paso 4 - λ e interpretación

Usando la ecuación (1):

$$\lambda = 50 - x + y = 50 - 44 + 18 = 24$$

$$\boxed{x^* = 44, \quad y^* = 18, \quad \lambda^* = 24}$$

Precio sombra altísimo
$\lambda = 24$: si finanzas nos da \$81k en vez de \$80k, el beneficio total sube \$24k. Retorno de 2400 % sobre cada dólar adicional de presupuesto.

¿Por qué tan alto? Porque estamos lejos de la saturación y la sinergia $+xy$ aporta mucho.

Ejemplo 5: enunciado

Una marca tiene **\$10 millones** de presupuesto publicitario. Lo divide entre:

- **TV tradicional** (y): retorno $5y$, lineal y seguro. Cada \$1M devuelve \$5M
- **Influencers** (x): retorno $-\frac{1}{3}x^3 + 5x^2 - 11x$. Volátil

Objetivo: maximizar ventas totales

$$V(x, y) = -\frac{1}{3}x^3 + 5x^2 - 11x + 5y$$

Restricción: $x + y = 10$

Ejemplo 5: ¿por qué cúbica?

Las inversiones en influencers tienen **tres fases**:

1. **Costo de entrada:** poca inversión $\Rightarrow$ nadie ve el contenido. Rendimiento *negativo* (el término $-11x$ domina)
2. **Viralidad:** al pasar cierto umbral, el contenido explota. Crecimiento rápido (el $+5x^2$ domina)
3. **Saturación:** después de mucho, el público se cansa. Rendimiento cae (el $-\frac{1}{3}x^3$ domina)

La forma cúbica es la manera matemática de capturar estas tres fases en una sola función.

Ejemplo 5: paso 1 y 2

Lagrangiano:

$$\mathcal{L}(x, y, \lambda) = \left(-\tfrac{1}{3}x^3 + 5x^2 - 11x + 5y\right) - \lambda(x + y - 10)$$

Derivadas:

$$(1) \quad \frac{\partial \mathcal{L}}{\partial x} = -x^2 + 10x - 11 - \lambda = 0$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial y} = 5 - \lambda = 0 \implies \boxed{\lambda = 5}$$

$$(3) \quad x + y = 10$$

Gran noticia: λ ya salió directamente de (2). Ahora lo usamos en (1).

Ejemplo 5: paso 3 - la cuadrática

Reemplazando $\lambda = 5$ en (1):

$$-x^2 + 10x - 11 - 5 = 0 \implies -x^2 + 10x - 16 = 0$$

Multiplicamos por (-1) para que el coeficiente principal sea positivo:

$$x^2 - 10x + 16 = 0$$

Aplicamos la resolvente de Bhaskara con $a = 1$, $b = -10$, $c = 16$:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} = \frac{10 \pm \sqrt{100 - 64}}{2} = \frac{10 \pm \sqrt{36}}{2} = \frac{10 \pm 6}{2}$$

Ejemplo 5: paso 3 - las dos raíces

La resolvente nos da **dos candidatos**:

$$x_1 = \frac{10+6}{2} = 8 \implies y_1 = 10 - 8 = 2 \quad \text{(Punto A)}$$

$$x_2 = \frac{10-6}{2} = 2 \implies y_2 = 10 - 2 = 8 \quad \text{(Punto B)}$$

Recordar

Lagrange es ciego: nos da candidatos pero no sabe cuál es el máximo. En el próximo paso evaluamos V en ambos.

Ejemplo 5: paso 4 - evaluar candidatos

Lagrange es ciego: nos da 2 candidatos pero no sabe cuál es máximo.
Evaluamos V en ambos.

Punto A $(x = 8, y = 2)$:

$$V(8,2) = -\tfrac{1}{3}(8)^3 + 5(8)^2 - 11(8) + 5(2)$$

$$= -\tfrac{512}{3} + 320 - 88 + 10 \approx -170{,}67 + 320 - 88 + 10 = 71{,}33$$

Punto B $(x = 2, y = 8)$:

$$V(2,8) = -\tfrac{1}{3}(2)^3 + 5(2)^2 - 11(2) + 5(8)$$

$$= -\tfrac{8}{3} + 20 - 22 + 40 \approx -2{,}67 + 20 - 22 + 40 = 35{,}33$$

Ejemplo 5: conclusión

$$\boxed{x^* = 8, \quad y^* = 2, \quad V^* \approx 71{,}33, \quad \lambda^* = 5}$$

Interpretación:

- **Punto A es el máximo**: con \$8M cruzamos el umbral de viralidad
- **Punto B es el mínimo local**: con \$2M pagamos el costo de entrada sin viralizar ("valle de la muerte")

Moraleja

Cuando la función objetivo **no es convexa** (acá, por el x^3), Lagrange puede dar múltiples candidatos. **Siempre evaluar cada uno** antes de decidir.

Ejemplo 5: Python con múltiples seeds

```python
from scipy.optimize import minimize

def ventas_neg(v):
    x, y = v
    return -(-1/3 * x**3 + 5*x**2 - 11*x + 5*y)

restricciones = [
    {'type': 'eq', 'fun': lambda v: v[0] + v[1] - 10}
]

bounds = [(0, None), (0, None)]

# Probamos varios puntos iniciales
puntos = [[1, 9], [3, 7], [5, 5], [7, 3], [9, 1]]
mejores = []
for x0 in puntos:
    res = minimize(ventas_neg, x0, method='SLSQP',
                   bounds=bounds, constraints=restricciones)
    if res.success:
        mejores.append((-res.fun, res.x))

mejores.sort(reverse=True)
print(f'Mejor: x={mejores[0][1][0]:.2f}, y={mejores[0][1][1]:.2f}')
```

KKT: ¿por qué necesitamos generalizar?

Hasta ahora: restricciones de **igualdad** ($g = 0$).

En la vida real son casi siempre **desigualdades**:

- "Gastá **como mucho** \$1000" $\Rightarrow x \leq 1000$
- "Producí **al menos** 50 unidades" $\Rightarrow x \geq 50$

Problema nuevo
No sabemos si la restricción es **relevante** en el óptimo.

- Óptimo libre cuesta \$300 $\Rightarrow$ el presupuesto \$1000 sobra
- Óptimo libre quería \$5000 $\Rightarrow$ la restricción **está activa**

KKT: planteo general

Problema estándar (minimización con $\leq$):

$$\text{mín}\, f(x) \quad \text{s.a.} \quad g_i(x) \leq 0, \quad i = 1, \ldots, m$$

Un multiplicador μ_i por cada restricción. Lagrangiano:

$$\mathcal{L}(x, \mu) = f(x) + \sum_{i=1}^{m} \mu_i \cdot g_i(x)$$

Cambio de signo

En Lagrange usábamos $f - \lambda g$. Acá usamos $f + \mu g$ (con $+$). Es **convención**: así los $\mu_i \geq 0$ tienen interpretación natural como precios sombra.

¿Cuándo aplicar KKT? (constraint qualifications)

KKT es **necesaria** para un óptimo, siempre que se cumpla alguna condición técnica llamada *constraint qualification*.

Las más usadas:

- **Slater** (convexos): existe un punto con $g_i < 0$ estricto
- **LICQ**: gradientes de restricciones activas linealmente independientes

En la práctica
La mayoría de los problemas bien planteados cumplen alguna. Asumimos que se cumple y aplicamos KKT.

Caso convexo + Slater: KKT es **necesaria y suficiente** (el punto que las cumpla es el óptimo global).

Las 4 condiciones KKT (1 y 2)

1. Estacionariedad

$$\nabla f(x^*) + \sum_i \mu_i \nabla g_i(x^*) = 0$$

El gradiente del Lagrangiano se anula.

2. Factibilidad primal

$$g_i(x^*) \leq 0 \quad \forall i$$

El punto cumple las restricciones.

Las 4 condiciones KKT (3 y 4)

3. Factibilidad dual

$$\mu_i \geq 0 \quad \forall i$$

Los precios sombra son no negativos.

4. Holgura complementaria

$$\mu_i \cdot g_i(x^*) = 0 \quad \forall i$$

O el multiplicador es cero, o la restricción está activa.

Holgura complementaria: el corazón de KKT

La condición 4 ($\mu_i \cdot g_i = 0$) dice que **uno de los dos** (o los dos) tiene que ser cero.

Dos escenarios posibles en el óptimo:

1. **Restricción inactiva** ($g_i < 0$): hay margen, no limita.
   - Entonces $\mu_i = 0$ forzosamente
   - Precio sombra cero: relajar la restricción no cambia nada
2. **Restricción activa** ($g_i = 0$): pegada al borde.
   - μ_i puede ser positivo
   - Precio sombra positivo: relajarla sí mejora el óptimo

En una frase
Las restricciones activas son las que "cuellan". Las inactivas sobran.

Caso degenerado: $\mu_i = 0$ y $g_i = 0$ a la vez

Hay un caso raro donde **ambos** son cero simultáneamente: la restricción está pegada al borde pero su multiplicador es cero.

Interpretación: la restricción toca el óptimo pero no está ejerciendo presión real. El óptimo se habría alcanzado igual sin ella.

La *holgura complementaria estricta* exige: *o* $\mu_i > 0$ *o* $g_i < 0$ (nunca los dos cero).

En la práctica
Casi nunca aparece en problemas de negocios. Mencionado por completitud: si alguna vez lo ven en un paper o ejercicio avanzado, sepan que existe.

¿Por qué $\mu_i \geq 0$?

Factibilidad dual exige que los multiplicadores sean no negativos. ¿Por qué?

Intuición económica: un precio sombra negativo significaría que relajar la restricción **empeora** el objetivo. Eso es absurdo: si la restricción nos está ayudando, no es realmente una restricción.

Intuición geométrica: en el óptimo, el gradiente de f apunta "hacia afuera" de la región factible. El gradiente de g_i también apunta hacia afuera (ya que $g_i \leq 0$ dentro, $g_i > 0$ fuera). Si están alineados, el factor que los relaciona es positivo.

Restricciones activas vs inactivas: visual

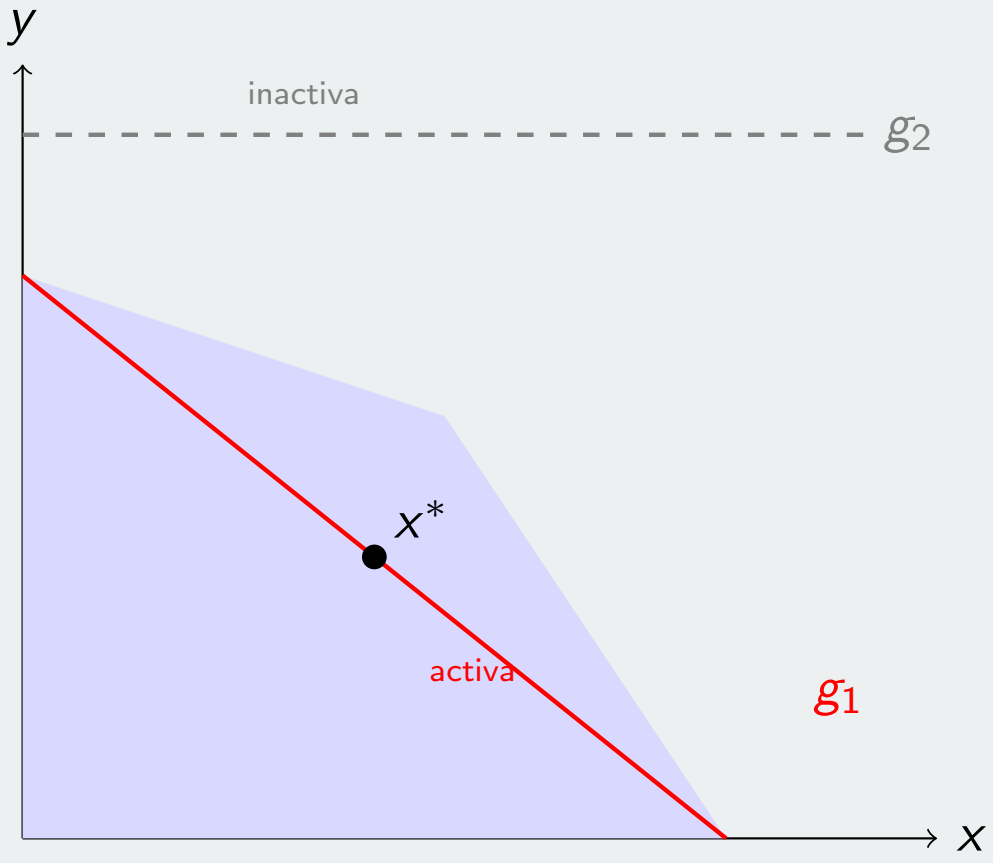

El óptimo x^* está **sobre** g_1 (activa) $\Rightarrow \mu_1 > 0$. Está **lejos de** g_2 (inactiva) $\Rightarrow \mu_2 = 0$.

Estrategia para resolver KKT a mano

No sabemos qué restricciones están activas. Entonces **probamos casos**.

1. **Asumir** una combinación de activas e inactivas
2. **Resolver** el sistema (Lagrange con las activas, las inactivas se ignoran)
3. **Verificar:** factibilidad primal (cumple todas) y dual ($\mu_i \geq 0$)
4. Si falla algo, probar otra combinación

Trick práctico

Arrancá probando "todas las restricciones activas". Si los μ_i dan todos positivos, listo. Si alguno da negativo $\Rightarrow$ esa restricción sobra, sacala y volvé a resolver.

Con m restricciones hay 2^m combinaciones. Para pocas ($m \leq 3$) se prueba a mano.

Ejemplo 6: enunciado

Una empresa produce dos artículos (x e y). La función de beneficio, con rendimientos decrecientes por saturación, es:

$$B(x, y) = 10x - x^2 + 10y - y^2$$

La producción tiene dos cuellos de botella:

- **Restricción 1 (Presupuesto):** $x + 2y \leq 14$
- **Restricción 2 (Horas hombre):** $2x + y \leq 14$

Objetivo: maximizar B.

Ejemplo 6: pasar a forma estándar

KKT trabaja con **minimización** y restricciones $g_i \leq 0$. Convertimos:

Maximizar B = minimizar $-B$:

$$\text{mín}\, f(x, y) = -(10x - x^2 + 10y - y^2) = -10x + x^2 - 10y + y^2$$

Restricciones en forma $g \leq 0$:

$$g_1(x, y) = x + 2y - 14 \leq 0$$

$$g_2(x, y) = 2x + y - 14 \leq 0$$

Ejemplo 6: paso 1 - Lagrangiano

Con dos restricciones, necesitamos **dos multiplicadores**:

$$\mathcal{L}(x, y, \mu_1, \mu_2) = -B(x, y) + \mu_1(x + 2y - 14) + \mu_2(2x + y - 14)$$

Expandiendo $-B$:

$$\mathcal{L} = -10x + x^2 - 10y + y^2 + \mu_1(x + 2y - 14) + \mu_2(2x + y - 14)$$

Ejemplo 6: paso 2 - estacionariedad

Derivamos respecto a x e y:

$$(1) \quad \frac{\partial \mathcal{L}}{\partial x} = -10 + 2x + \mu_1 + 2\mu_2 = 0$$

$$(2) \quad \frac{\partial \mathcal{L}}{\partial y} = -10 + 2y + 2\mu_1 + \mu_2 = 0$$

No derivamos respecto a μ_i directamente: esas condiciones las reemplaza la **holgura complementaria**.

Ejemplo 6: paso 3 - probar casos

Tenemos $2^2 = 4$ combinaciones de activas/inactivas:

- **Caso A:** ninguna activa $\Rightarrow \mu_1 = \mu_2 = 0$
- **Caso B:** solo la 1 activa $\Rightarrow \mu_2 = 0$, $g_1 = 0$
- **Caso C:** solo la 2 activa $\Rightarrow \mu_1 = 0$, $g_2 = 0$
- **Caso D:** ambas activas $\Rightarrow g_1 = 0$, $g_2 = 0$

Arrancamos por el caso A (el más simple).

Ejemplo 6: Caso A - ninguna activa

Si $\mu_1 = \mu_2 = 0$, las ecuaciones (1) y (2) quedan:

$$-10 + 2x = 0 \implies x = 5$$

$$-10 + 2y = 0 \implies y = 5$$

¿Cumple las restricciones? Verificamos g_1:

$$5 + 2(5) = 15 \not\leq 14$$

Viola la restricción 1
El óptimo libre cae fuera de la región factible. Descartamos este caso.

Pasamos al Caso D (ambas activas).

Ejemplo 6: Caso D - ambas activas

Si ambas están activas: $g_1 = 0$ y $g_2 = 0$.

$$\begin{cases} x + 2y = 14 \\ 2x + y = 14 \end{cases}$$

Multiplicamos la segunda por 2:

$$\begin{cases} x + 2y = 14 \\ 4x + 2y = 28 \end{cases}$$

Ejemplo 6: Caso D - resolviendo

Restamos la primera de la segunda:

$$(4x + 2y) - (x + 2y) = 28 - 14 \implies 3x = 14 \implies x = \frac{14}{3} \approx 4{,}67$$

Reemplazando en $x + 2y = 14$:

$$y = 14 - 2 \cdot \frac{14}{3} = \frac{42-28}{3} = \frac{14}{3}$$

Entonces $x = y = \frac{14}{3}$. Falta verificar que los $\mu_i \geq 0$.

Ejemplo 6: verificar multiplicadores

Ahora usamos (1) y (2) con $x = y = 14/3$:

$$-10 + 2 \cdot \tfrac{14}{3} + \mu_1 + 2\mu_2 = 0 \implies \mu_1 + 2\mu_2 = 10 - \tfrac{28}{3} = \tfrac{2}{3}$$

$$-10 + 2 \cdot \tfrac{14}{3} + 2\mu_1 + \mu_2 = 0 \implies 2\mu_1 + \mu_2 = \tfrac{2}{3}$$

Restando las dos:

$$(2\mu_1 + \mu_2) - (\mu_1 + 2\mu_2) = 0 \implies \mu_1 - \mu_2 = 0 \implies \mu_1 = \mu_2$$

Reemplazando: $\mu_1 + 2\mu_1 = \frac{2}{3} \implies 3\mu_1 = \frac{2}{3} \implies \mu_1 = \frac{2}{9}$

Ejemplo 6: verificación KKT

Chequeamos las 4 condiciones KKT:

- **Estacionariedad:** ✓(lo usamos para derivar las ecuaciones)
- **Factibilidad primal:** $x, y = 14/3 \geq 0$, restricciones con igualdad. ✓
- **Factibilidad dual:** $\mu_1 = \mu_2 = 2/9 > 0$. ✓
- **Holgura complementaria:** ambas restricciones activas ($g_i = 0$) con $\mu_i > 0$. ✓

$$\boxed{x^* = y^* = \tfrac{14}{3} \approx 4{,}67, \quad \mu_1^* = \mu_2^* = \tfrac{2}{9} \approx 0{,}22}$$

Ejemplo 6: interpretación

Estrategia productiva: producir $\approx 4{,}67$ de cada artículo, **agotando ambos recursos simultáneamente**. La empresa queda en una *esquina* de la región factible.

Precios sombra iguales ($\mu_1 = \mu_2 = 0{,}22$):

- Conseguir \$1 extra de presupuesto $\Rightarrow$ +\$0.22k de beneficio
- Conseguir 1 hora hombre extra $\Rightarrow$ +\$0.22k de beneficio

Implicancia gerencial
Si tuviéramos que elegir qué recurso conseguir primero, **da igual**: ambos rinden lo mismo. Si uno fuera más barato de conseguir, iríamos con el más barato.

Ejemplo 7: cuando una restricción sobra

Hasta ahora los ejemplos KKT tenían las restricciones activas. Pero a veces asumimos que una está activa, resolvemos, **y nos da μ negativo**. Ese es el caso donde hay que **descartar** y probar con la restricción inactiva.

Problema simple:

$$\text{mín}\, f(x, y) = x^2 + y^2 \quad \text{s.a.} \quad x + y \leq 2$$

En forma estándar: $g(x, y) = x + y - 2 \leq 0$.

Ejemplo 7: asumimos que la restricción está activa

Si $g = 0$ el problema se convierte en Lagrange puro:

$$\mathcal{L} = x^2 + y^2 + \mu(x + y - 2)$$

Derivadas:

- $2x + \mu = 0 \Rightarrow \mu = -2x$
- $2y + \mu = 0 \Rightarrow \mu = -2y$
- $x + y = 2$

De las dos primeras: $x = y$. Reemplazando: $x = y = 1$.

$$\mu = -2 \cdot 1 = -2$$

Ejemplo 7: μ salió negativo

Problema
La factibilidad dual exige $\mu \geq 0$. Acá $\mu = -2 < 0$. **Descartamos este caso.**

Interpretación: un $\mu < 0$ diría que relajar la restricción (subir el límite de 2 a 3) *empeora* el objetivo. Es absurdo: lo que pasa es que **la restricción nunca estuvo limitando**.

Próximo paso: probamos con la restricción inactiva ($\mu = 0$).

Ejemplo 7: caso inactivo

Si $\mu = 0$, el problema queda sin restricciones:

$$\text{mín}\, x^2 + y^2$$

El mínimo es trivialmente $(0, 0)$ con $f = 0$.

Verificamos factibilidad primal:

$$0 + 0 = 0 \leq 2 \quad \checkmark$$

La restricción se cumple con holgura. Holgura complementaria:
$\mu \cdot g = 0 \cdot (-2) = 0$. ✓

$$\boxed{x^* = y^* = 0, \quad \mu^* = 0, \quad f^* = 0}$$

Ejemplo 7: moraleja

Procedimiento típico con desigualdades:

1. Probás una combinación de activas/inactivas
2. Resolvés el sistema
3. Si algún $\mu_i < 0 \Rightarrow$ **descartar**
4. Probás con esa restricción inactiva
5. Verificás factibilidad primal del nuevo óptimo

Geometría del caso

El óptimo libre $(0, 0)$ ya está dentro de la región factible. No hay por qué empujarlo al borde. La restricción $x + y = 2$ "está ahí" pero no toca.

Lagrange vs KKT: tabla resumen

Aspecto	**Lagrange**	**KKT**
Restricciones	$g = 0$	$g \leq 0$
Multiplicadores	λ (signo libre)	$\mu \geq 0$
Lagrangiano	$f - \lambda g$	$f + \mu g$
Condiciones	$\nabla \mathcal{L} = 0$	Las 4 KKT

Cuándo usar qué en la práctica:

- Problema chico y analítico $\Rightarrow$ Lagrange/KKT a mano (ganás intuición)
- Problema grande o sin forma cerrada $\Rightarrow$ Python con `scipy`
- Necesitás precios sombra $\Rightarrow$ solvers que los devuelvan (`cvxpy`, `pulp`)

Diccionario: matemática - geometría - negocio

Matemática	**Geometría**	**Negocio**
∇f	Dirección de crecimiento	Hacia dónde invertir
λ o μ	Escala entre gradientes	Precio sombra
Tangencia	Curvas que se tocan	Equilibrio beneficio-costo
$g_i = 0$	Punto en la frontera	Recurso agotado
$\mu_i = 0$	Punto en el interior	Recurso sobra

Para llevarse de la clase

1. El **Lagrangiano** es la forma compacta de pedir gradientes paralelos y restricción cumplida
2. λ (o μ) es el **precio sombra**: cuánto vale relajar la restricción en una unidad
3. **KKT** generaliza a desigualdades con la **holgura complementaria**: o la restricción está activa o el multiplicador es cero
4. Si la función **no es convexa**, puede haber varios candidatos. **Siempre evaluar todos**
5. En problemas KKT a mano, **probar casos**: asumir qué restricciones están activas y verificar

Terminamos

¿Dudas?

¿Consultas?

Universidad de SanAndrés